Лабораторная работа №5

Ансамбли моделей машинного обучения

Задание:

1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
4. Обучите следующие ансамблевые модели:
   - одну из моделей группы бэггинга (бэггинг или случайный лес или сверхслучайные деревья);
   - одну из моделей группы бустинга;
   - одну из моделей группы стекинга.
5. (+1 балл на экзамене) Дополнительно к указанным моделям обучите еще две модели:
   - Модель многослойного персептрона. По желанию, вместо библиотеки scikit-learn возможно использование библиотек TensorFlow, PyTorch или других аналогичных библиотек.
   - Модель МГУА с использованием библиотеки - https://github.com/kvoyager/GmdhPy (или аналогичных библиотек). Найдите такие параметры запуска модели, при которых она будет по крайней мере не хуже, чем одна из предыдущих ансамблевых моделей.
6. Оцените качество моделей с помощью одной из подходящих для задачи метрик. Сравните качество полученных моделей.

In [174…
```
from sklearn.impute import SimpleImputer
from sklearn.impute import MissingIndicator
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from typing import Tuple
from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.svm import SVC
from sklearn.metrics import mean_squared_error, mean_absolute_error
from sklearn.tree import DecisionTreeClassifier
import graphviz
from sklearn.tree import export_graphviz
from sklearn import tree
from operator import itemgetter
from sklearn.ensemble import RandomForestClassifier,RandomForestRegressor, StackingRegress
from sklearn.linear_model import LogisticRegression, LinearRegression
```

In [134…
```
data = pd.read_csv("powerplants (global) - global_power_plants.csv")
```

In [180…
```
type(data)
```

Out[180… `pandas.core.frame.DataFrame`

In [135…
```
#Первые 5 записей датасета
```

```
data.head()
```

Out[135…

	country code	country	name of powerplant	capacity in MW	latitude	longitude	primary_fuel	secondary fuel	other_fuel 1	other_fuel 2
0	AFG	Afghanistan	Kajaki Hydroelectric Power Plant Afghanistan	33.0	32.322	65.1190	Hydro	NaN	NaN	NaN
1	AFG	Afghanistan	Kandahar DOG	10.0	31.670	65.7950	Solar	NaN	NaN	NaN
2	AFG	Afghanistan	Kandahar JOL	10.0	31.623	65.7920	Solar	NaN	NaN	NaN
3	AFG	Afghanistan	Mahipar Hydroelectric Power Plant Afghanistan	66.0	34.556	69.4787	Hydro	NaN	NaN	NaN
4	AFG	Afghanistan	Naghlu Dam Hydroelectric Power Plant Afghanistan	100.0	34.641	69.7170	Hydro	NaN	NaN	NaN

In [136…

```
#Проверка наличия пустых значений
data.isnull().sum()
```

Out[136…

```
country code                       0
country                            0
name of powerplant                 0
capacity in MW                     0
latitude                           0
longitude                          0
primary_fuel                       0
secondary fuel                 32992
other_fuel 1                   34660
other_fuel 2                   34844
start date                     17489
owner of plant                 14068
geolocation_source               419
generation_gwh_2020            25277
generation_data_source         23536
estimated_generation_gwh_2020   1798
dtype: int64
```

In [137…

```
#Размер исходного датасета
data.shape
```

Out[137…

```
(34936, 16)
```

In [138…

```
#Проверка типов
data.dtypes
```

Out[138…

```
country code                    object
country                         object
name of powerplant              object
capacity in MW                 float64
latitude                       float64
longitude                      float64
```

```
primary_fuel                    object
secondary fuel                  object
other_fuel 1                    object
other_fuel 2                    object
start date                     float64
owner of plant                  object
geolocation_source              object
generation_gwh_2020            float64
generation_data_source          object
estimated_generation_gwh_2020  float64
dtype: object
```

In [139…

```
def test_num_impute_col(dataset, column, strategy_param):
    temp_data = dataset[[column]]

    indicator = MissingIndicator()
    mask_missing_values_only = indicator.fit_transform(temp_data)

    imp_num = SimpleImputer(strategy=strategy_param)
    data_num_imp = imp_num.fit_transform(temp_data)

    filled_data = data_num_imp[mask_missing_values_only]
    dataset[column] = data_num_imp
    return column, strategy_param, filled_data.size, filled_data[0], filled_data[filled_da
```

In [140…

```
#Удаление ненужных столбцов
data = data.drop(columns=["generation_gwh_2020","country", "primary_fuel","secondary fuel"
#test_num_impute_col(data, 'generation_gwh_2020', 'median')
```

In [141…

```
#Кодирование категориальных признаков
#LE = LabelEncoder()
#for column in ["country","primary_fuel"]:
#    data[column] = LE.fit_transform(data[column])
```

In [142…

```
data.isnull().sum()
```

Out[142…

```
capacity in MW                    0
latitude                          0
longitude                         0
estimated_generation_gwh_2020    1798
dtype: int64
```

In [143…

```
data = data.dropna(axis=0, how='any')
```

In [144…

```
data.isnull().sum()
```

Out[144…

```
capacity in MW                   0
latitude                         0
longitude                        0
estimated_generation_gwh_2020    0
dtype: int64
```

In [145…

```
data.head()
```

Out[145…

	capacity in MW	latitude	longitude	estimated_generation_gwh_2020
0	33.0	32.322	65.1190	119.50

	capacity in MW	latitude	longitude	estimated_generation_gwh_2020
1	10.0	31.670	65.7950	18.29
2	10.0	31.623	65.7920	18.72
3	66.0	34.556	69.4787	174.91
4	100.0	34.641	69.7170	350.80

In [146…
```
data.dtypes
```

Out[146…
```
capacity in MW                    float64
latitude                          float64
longitude                         float64
estimated_generation_gwh_2020     float64
dtype: object
```

In [147…
```
fig, ax = plt.subplots(figsize=(15,9))
sns.heatmap(data.corr(method='pearson'), ax=ax, annot=True, fmt='.2f')
```

Out[147…
```
<AxesSubplot:>
```

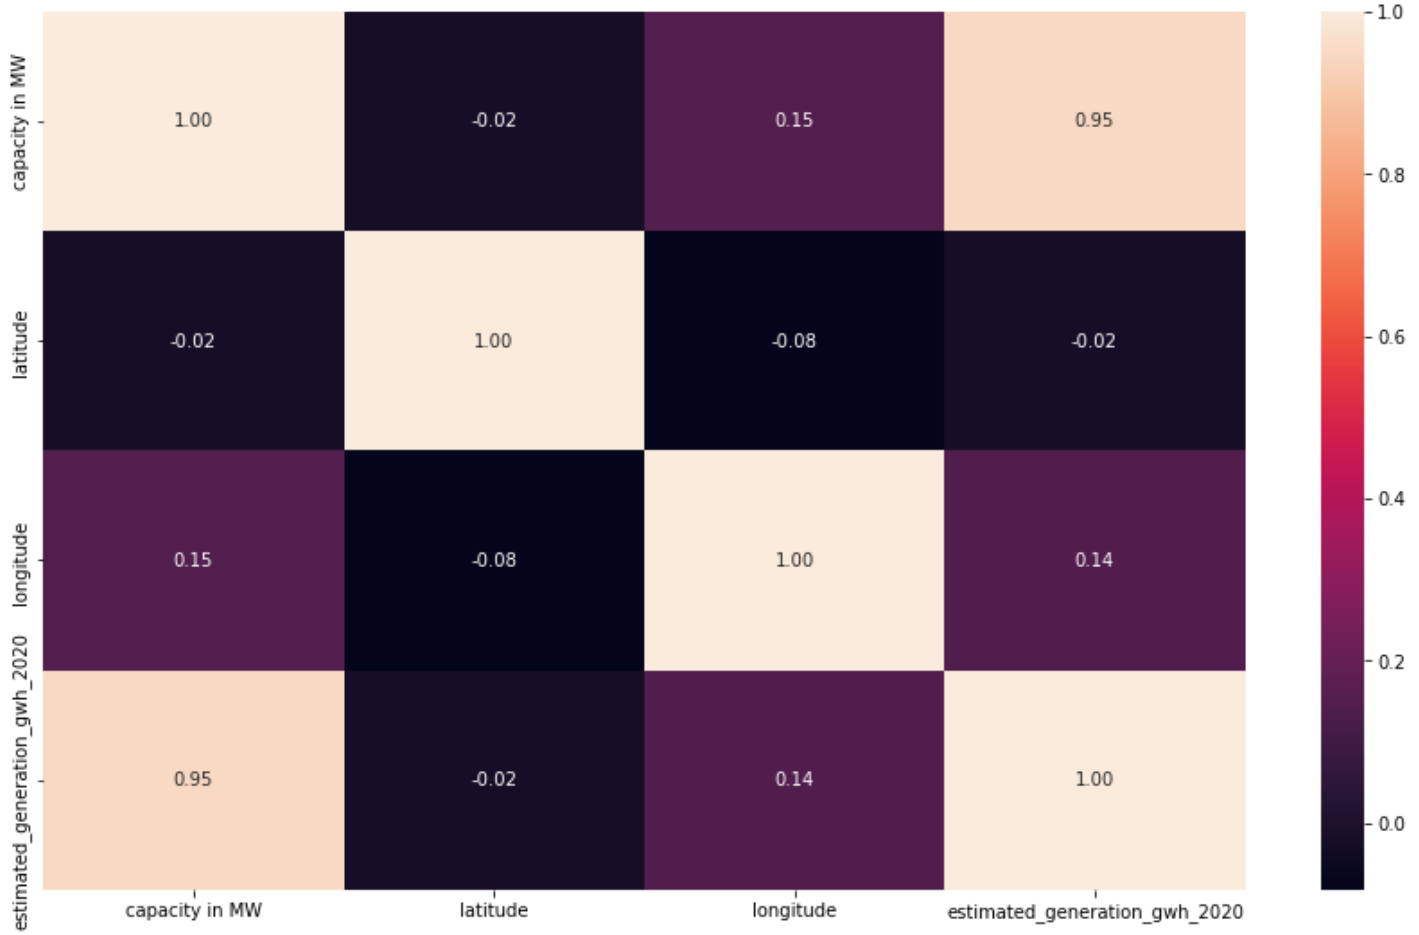

In [148…
```
xArray = data.drop("estimated_generation_gwh_2020", axis=1)
yArray = data["estimated_generation_gwh_2020"]
```

In [149…
```
#Разделяем выборку для обучения модели
trainX, testX, trainY, testY = train_test_split(xArray, yArray, test_size=0.2, random_stat
trainX, testX, trainY, testY
```

```
(       capacity in MW  latitude  longitude
```

Out[149…
```
21809            4.60   38.6522    35.7591
13159           26.00   51.3698     6.6615
2127             1.08  -15.5920   -56.0875
7470            30.00   22.7500   115.4167
11823           26.00   45.1481     3.2920
...               ...       ...        ...
8435            96.00   37.5600   105.0170
34282            1.30   33.9347  -116.6405
5814            48.00   25.3800   119.4500
13057           30.00   52.4903    13.8299
34799         1120.00   21.0725   107.3500

[26510 rows x 3 columns],
       capacity in MW  latitude  longitude
12039         18.7102   43.6121     4.8564
15879       1779.6000   36.8387    53.2593
5733          20.0000   33.3490   113.0820
17462        449.0000   25.7192  -100.1017
21475        114.0000   12.7547   101.1637
...               ...       ...        ...
29180          1.0000   33.9192  -118.1286
34096        774.0000   47.9469  -119.8653
837           12.0000   47.1667    15.3333
13190         45.0000   51.7212    11.9600
10723          8.7000   43.5410     5.8410

[6628 rows x 3 columns],
21809       8.60
13159     127.82
2127        2.13
7470       55.66
11823      47.54
           ...
8435      149.96
34282       2.56
5814       89.06
13057      63.12
34799    5577.33
Name: estimated_generation_gwh_2020, Length: 26510, dtype: float64,
12039      36.31
15879    4905.45
5733       36.05
17462    3522.24
21475     498.53
           ...
29180       0.18
34096    3037.80
837        50.77
13190      63.57
10723      16.10
Name: estimated_generation_gwh_2020, Length: 6628, dtype: float64)
```

Случайный лес

In [155…
```
RForest = RandomForestRegressor(n_estimators=5, oob_score=True, random_state=10)
RForest.fit(trainX, trainY)
```

```
D:\Programs\anaconda3\lib\site-packages\sklearn\ensemble\_forest.py:833: UserWarning: Some
inputs do not have OOB scores. This probably means too few trees were used to compute any
reliable oob estimates.
  warn("Some inputs do not have OOB scores. "
```

Out[155…
```
RandomForestRegressor(n_estimators=5, oob_score=True, random_state=10)
```

In [156…
```
RForest.predict(testX)
```

Out[156…
```
array([  35.19 , 6591.728,   36.19 , ...,   25.548,   95.982,   27.772])
```

In [157…
```
estimateRF = mean_absolute_error(testY, RForest.predict(testX))
estimateRF
```

Out[157…
```
176.03807412995374
```

In [165…
```
RForestarr = list()
RForest = RandomForestRegressor(n_estimators=100, oob_score=True, random_state=10)
RForest.fit(trainX, trainY)
RForestarr.append(mean_absolute_error(testY, RForest.predict(testX)))
```

In [178…
```
RForest = RandomForestRegressor(n_estimators=200, oob_score=True, random_state=10)
RForest.fit(trainX, trainY)
RForestarr.append(mean_absolute_error(testY, RForest.predict(testX)))
```

In [179…
```
RForestarr
```

Out[179…
```
[164.59361515554505, 164.58021531213186]
```

Boosting

In [170…
```
GB = GradientBoostingRegressor(random_state=1)
GB.fit(trainX, trainY)
```

Out[170…
```
GradientBoostingRegressor(random_state=1)
```

In [171…
```
mean_absolute_error(testY, GB.predict(testX))
```

Out[171…
```
182.06374404338914
```

Stacking

In [175…
```
base_learners = [
                 ('RF', RandomForestRegressor(n_estimators=10, random_state=1)),
                 ('GB', GradientBoostingRegressor(n_estimators=10, random_state=1))
                ]

SC = StackingRegressor(estimators=base_learners, final_estimator=LinearRegression())
SC.fit(trainX, trainY)
```

Out[175…
```
StackingRegressor(estimators=[('RF',
                               RandomForestRegressor(n_estimators=10,
                                                     random_state=1)),
                              ('GB',
                               GradientBoostingRegressor(n_estimators=10,
                                                         random_state=1))],
                  final_estimator=LinearRegression())
```

In [177…
```
mean_absolute_error(testY, SC.predict(testX))
```

Out[177… 187.3790040119118

In [ ]: